

Action和Plugin之重调度、 分时复用、任务拓扑

目录

01 Shuffle Action

02 Rescheduling Plugin

03 TDM Plugin

04 Task Topology Plugin





01

Shuffle Action



Shuffle Action

- Shuffle action旨在不同节点间进行负载再平衡
- 推荐与shuffle action配合使用的插件为: **TDM, Rescheduling**
- shuffle action将会遍历所有Pods, 筛选出不符合要求的Pods并尝试驱逐它们
- 被选定为受害者的Pods将会被调度到负载合适的节点上



02

Rescheduling Plugin



背景

- 不合理的调度策略和作业生命周期的动态变化导致节点间不均衡的资源利用率
- 诸如增加/删除节点、Pod/Node的亲和性配置改变导致节点状态发生变化



概念

- **资源筛选器**

筛选出具有某些特征的Pod. 这些Pod将**可能**被驱逐

- 队列筛选器: 仅筛选出属于某个队列的Pod
- 标签筛选器: 仅筛选出具有指定标签的Pod


- **重调度策略**

决定了哪些Pod将被驱逐; 将会按照配置的先后顺序依次执行

重调度策略

- **OfflineOnly**
筛选出离线任务，这些任务被打上了**preemptable: true**的annotation
- **LowPriorityFirst**
根据优先级对作业进行排序，按照优先级顺序从低向高进行驱逐
- **ShortLifeTimeFirst**
根据运行时长对作业进行排序，运行时长最短的Pod将被先驱逐。
- **BigObjectFirst**
对**主导型资源**需求最多的作业将被优先驱逐。
- **MoreReplicasFirst**
根据副本数对作业进行排序，具有最多副本数的作业会被优先驱逐

工作流程



- 筛选器依次工作，筛选出潜在的受害者作业
- VictimFns依次工作，选出待驱逐的Pod
- 根据配置的轮询周期，定期执行以上过程

配置

```
actions: "enqueue, allocate, backfill, shuffle" ## 将shuffle action添加在最后
tiers:
- plugins:
  - name: rescheduling      ## rescheduling插件
    arguments:
      interval: 5m          ## 可选项, 重调度策略工作周期, 默认5分钟一次
      strategies:          ## 必选项, 依次工作的重调度策略
        - name: offlineOnly
        - name: lowPriorityFirst
        - name: lowNodeUtilization
      params:
        nodeResourceUtilizationThresholds:
          thresholds:
            "cpu" : 20
            "memory": 20
            "pods": 20
          targetThresholds:
            "cpu" : 50
            "memory": 50
            "pods": 50
      queueSelector:      ## 可选项, 选出指定队列中的潜在受害者, 默认值为所有队列
        - default
        - test-queue
      labelSelector:      ## optional, 选出具有指定标签的潜在受害者, 默认值为所有标签
        business: offline
        team: test
```



03

TDM Plugin




背景

- 在离线业务分布在不同集群且潮汐效应明显，如Kubernetes和Yarn集群
- 为了最大限度使用集群资源，部分节点可以分时段被纳管到不同集群



工作流程



- 可回收节点:** 将这类节点打上`volcano.sh/revocable-zone: xxx`标签, 表明该节点同时从属于Kubernetes和Yarn集群。它的值表示该节点所属可回收区与工作时间段。
- 可回收区:** 同时从属于多个集群的节点构成的节点组, 定义了该组节点在不同集群中的工作时间段。
- 可抢占负载:** 具有annotation `volcano.sh/preemptable: "true"` 的volcano job将优先被绑定到可回收区中的节点。
- 可用时段:** 在指定可回收区中的节点在该时段内将被纳管到Kubernetes集群

配置

actions: "enqueue, allocate, backfill, shuffle"

tiers:

- plugins:

- name: **tdm**

- arguments:

- tdm.revocable-zone.rz1: 1:00-4:00**

- tdm.evict.period: 1m**



04

Task Topology Plugin




背景

- 在AI和大数据领域，同一作业中的不同角色的网络通信时延可能在总运行时长中占比较大，如TensorFlow和Spark
- 如果在调度层面将这类耗时纳入考量，如将PS和worker尽可能绑定在同一节点，将极大减少作业的运行时长，提高效率



工作流程



设计文档: <https://github.com/volcano-sh/volcano/blob/master/docs/design/task-topology-plugin.md>

调度器配置

actions: "enqueue, allocate, backfill"

tiers:

- plugins:

- name: **task-topology**

arguments:

task-topology.weight: 10



作业配置

apiVersion: batch.volcano.sh/v1alpha1

kind: Job

metadata:

name: tensorflow-dist-mnist

annotations:

volcano.sh/task-topology-affinity: "ps,worker;"

ps 和 worker 具有亲和性, 优先被绑定到同一节点

volcano.sh/task-topology-anti-affinity: "ps; "

ps具有反亲和性, 尽量绑定到不同节点

volcano.sh/task-topology-task-order: "ps,worker;"

Pod进行排序时, ps优先

spec:

minAvailable: 3

schedulerName: volcano

plugins:

env: []

svc: []

tasks:

- replicas: 2

name: ps

template:

spec:

...

- replicas: 4

name: worker

policies:

- event: TaskCompleted

action: CompleteJob

template:

spec:

...



加入Volcano社区



官网: <https://volcano.sh/en/>



Github: <https://github.com/volcano-sh/volcano>




Slack Channel: <https://volcano-sh.slack.com/>



关注我们



加入技术交流群



Thanks